Spark Patents

NVIDIA DGX SPARK Hackathon 2026

Spark Folks 小组项目报告书

- 队长：**梅荻**
  - 人工智能研究员/工程师
  - ***RISC-V International Open Source Lab (RIOS)***，清华大学深圳国际研究生院
- 队员：**黄玟瑜**
  - 数据科学和信息技术 2024级研究生
  - ***RISC-V International Open Source Lab (RIOS)***，清华大学深圳国际研究生院
- 队员：**蔡玄邦（Winston Cai）**
  - 数据科学和信息技术 2025级研究生
  - ***High Performance Geo-Computing Research-Group (HPGC)***，清华大学深圳国际研究生院

Spark Patents 项目介绍

项目背景

在当今知识经济与数字化深度融合的时代，**知识产权（IP）**已成为驱动创新、维系公平竞争和塑造国家与企业核心竞争力的战略基石。它通过法律赋权切实保护创作者与研发者的智力成果，持续激发技术突破与文化繁荣；在全球产业链加速重构的背景下，专利、商标、版权及商业秘密等无形资产更是企业抢占市场先机、实现高附加值转型的关键筹码。面对人工智能、开源生态与数据跨境流动等新兴挑战，完善的 IP 制度既能划定权利边界、遏制侵权与垄断，又能通过许可、交易与标准化机制促进技术共享与跨界协同，为高质量发展、可持续创新及全球科技治理提供坚实支撑，最终推动人类社会在尊重智慧价值的基础上迈向更加繁荣的未来。

RISC-V 国际开源实验室（RIOS Lab）早在 2022 年就已经开始布局 IP 研究，受益于大规模语言模型等前沿技术的高速推动，在高质量专利数据库和 IP 领域内知识积累（来自 IP 律师、学者）的基础上成功自动化了诸多专利处理上的工作流程，用于帮助 IP 从业者极大地提升工作效率。例如在专利的稳定性分析场景下，原本专利律师需要耗时至少 2～3 周，但有了高效的专利推荐和语义分析工具以后，该流程可以缩短至几分钟内。感谢 **NVIDIA DGX SPARK Hackathon 2026** 赛办方的组织和**清华大学高性能计算实验室（HPGC Lab）**提供的人员和算力硬件支持，我们首次将多维度专利处理智能体化并部署在前沿的 AI 推理硬件上，这些多维度的服务涉及专利检索、专利推荐（IP 保护）、单专利语义分析、

跨专利语义分析、专利智能问数（统计分析）、技术问答（深度分析）等。**出于成果隐私保护，该项目的代码暂时不开源，并且当前成果仍处于轻量化的概念验证阶段（PoC），但会在未来完善后以 RIOS Lab 开源专利平台的形式开放给公众使用和二次开发。**

成果核心优势

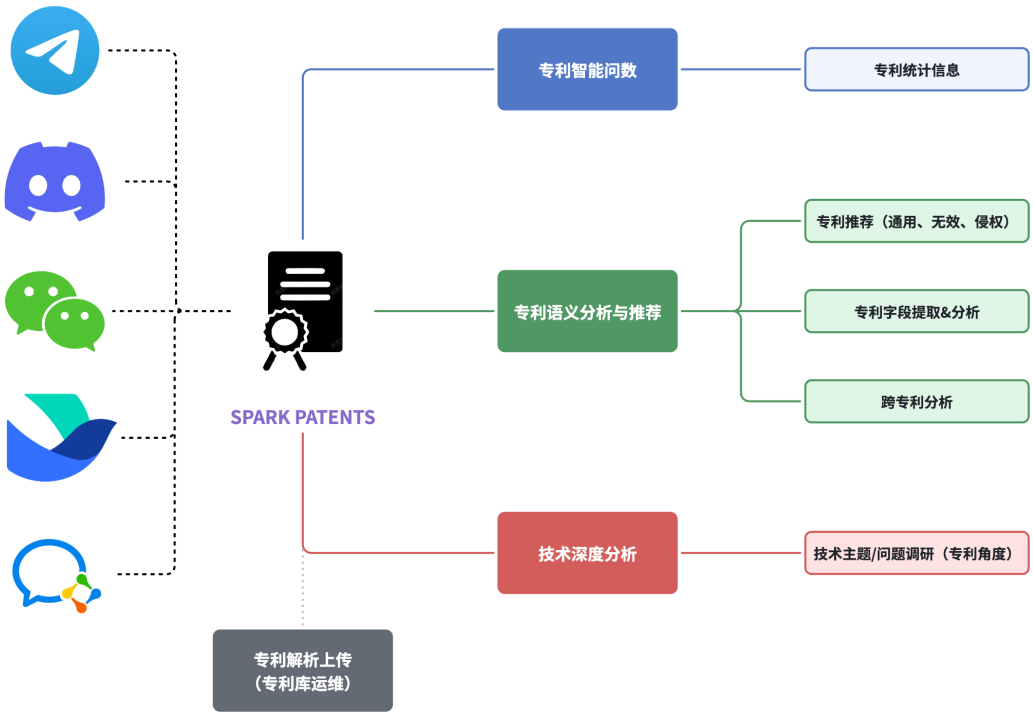

Spark Patents 功能模块

- **市面上专利处理维度最全面的AI智能体**：涉及专利语义分析与推荐、专利智能问数、技术深度分析、原始专利解析与上传四大功能模块。
  - ***同类竞品比较***

知识产权平台	PatSea	玻尔	智慧芽 Eureka	Spark Patents
数据类型	专利 其他文献	学术文献 （主要是论文）	专利 其他文献	**目前仅专利**
Agent 交互	不支持	支持	支持	**支持**
主要服务类型	文献检索 文献语义分析	技术深度分析 技术问答 文献检索	技术深度分析 技术问答 文献检索 说明书撰写	**技术深度分析** **技术问答** **专利检索/推荐** **专利语义分析** **专利智能问数(统计分析)**

使用平台	官方平台	官方平台	官方平台	**RIOS 开源网站或支持主流通信 APP 接入**
全功能开放是否收费	是	是	是	**未来计划由 RIOS Lab 开源**

- **智能体的垂类专业性**：集成了知识产权律师和学者的领域内知识。
- **用户友好交互**：支持 10+ 主流通信 APP 的集成，如微信、企业微信、飞书、Discord等。
- **基建的可靠性**：基于英伟达高性能推理硬件 DGX Spark 和 CUDA 加速框架，成功搭建支持高并发请求、适配多元数据存储、具备灵活可扩展性的 Agent 基建。
  - 大模型服务节点的可扩展性：负载均衡模块支持
  - 数据库的可扩展性：Milvus & PostgreSQL -> Elastic
  - 通用智能体框架的可扩展性：Nanobot -> OpenClaw 或 集成更多的技能

人员分工

- **梅荻**（队长）
  - 项目策划 + 技术方案提出 + 人员分工
  - 技术实现：大模型/嵌入模型下载与部署、负载均衡、业务算法（专利语义分析与推荐、技术深度分析）、智能体集成（技能、.md文件）
  - 递交材料准备：视频剪辑、技术报告撰写、Github 仓库
- **黄玟瑜**（队员）
  - 技术实现：DGX Spark 配置、业务算法（智能问数）、专利库部署与预填充、原始专利上传与解析、智能体集成（技能、.md文件）
  - 递交材料准备：Demo 素材准备（原始专利上传与解析）、技术报告撰写、Github 仓库
- **蔡玄邦**（队员）
  - 技术实现：通用智能体框架调研与部署、前端适配、智能体集成（技能、.md文件）
  - 递交材料准备：Demo 素材准备（专利语义分析与推荐、智能问数、技术深度分析）

Spark Patents 技术实现

技术框架图

以下所有模块皆部署在一台 DGX Spark 机器上。

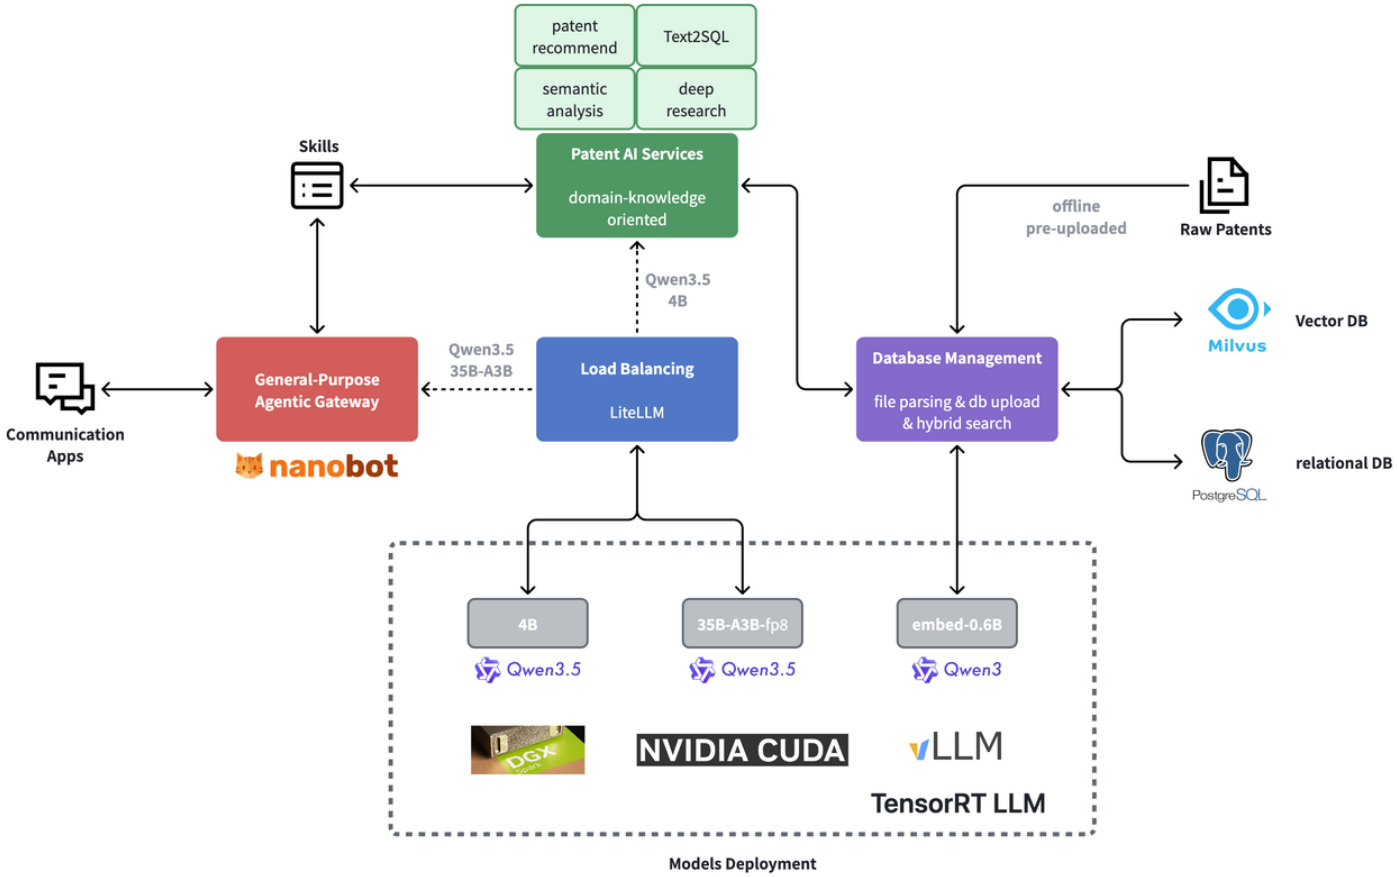

模型部署 - Models Deployment

模型选择

- **Qwen3.5-35B-A3B-fp8**
  - 主要接入通用智能体框架（比如 OpenClaw、Nanobot）。
  - MOE 模型具备高效推理的优势，适合处理长会话，同时千问这款最新发布的模型具备不错的跑分表现。
- **Qwen3.5-4B (fp8 量化部署)**
  - 主要用于专利 AI 服务的实现（比如专利语义分析、参与推荐工作流）。
  - 内存消耗小，并且小规模的 dense 模型在单轮对话上具备不错的效果和效率。
- **Qwen3-Embedding-0.6B**
  - 用于专利向量库的搭建。

模型部署

模型部署上我们尝试了不同的部署框架，两种框架均能适配本项目，DGX Spark 上面的 **CUDA 驱动和 CUDA Toolkit** 配置如下所示：

```
DGX Spark
Driver Version: 580.82.09      CUDA Version: 13.0
```

选择一：vLLM

- vLLM 支持多请求下的动态批处理（连续批处理），35B 大模型所配置的单个最大窗口长度（max-model-len）为 32768，4B 则为16384，嵌入模型为8192，并发（max-num-seqs）设定成 2。
- 注意力后端使用了**英伟达的 "TRITON Fp8 MoE backend"**，若部署 Nemotron3 系列模型，则需要使用 **"MARLIN"**。
- 35B、4B、0.6B 模型的内存占有率分别是：0.4，0.1，0.1（共消耗 90Gb 左右）。
- 提示词缓存开启（enable-prefix-caching）。
- 思考模式均关闭。

选择二：TensorRT-LLM by NVIDIA

- TensorRT-LLM 支持多请求下的动态批处理（连续批处理），35B 大模型所配置的单个最大窗口长度（max_seq_len）为 32768，4B 则为16384，嵌入模型为8192，并发（max_batch_size）设定成 2。
- KV-cache 的内存占有率通过 kv_cache_free_gpu_memory_fraction 配置。
- 提示词缓存开启 "enable_kv_cache_reuse"。
- 思考模式均关闭。

负载均衡 - Load Balancing

大模型（35B、4B、0.6B）的负载均衡主要借助了 LiteLLM 框架，主要是针对于多模型多节点部署这一场景。尽管在项目搭建过程中所有模型和服务都被部署在一台机器上，但负载均衡模块的参与能够有效地帮助项目扩展规模。

在配置负载均衡时，需着重考虑：

- **RPM（每分钟的请求限制）**：过大的 RPM 会导致大模型服务器请求堵塞，导致上层应用超时；过小的 RPM 则会浪费大模型服务器资源。
- **路由策略**：也就是负载均衡策略，决定了如何分发请求至不同的节点上（默认 simple-shuffle）。

专利 AI 服务 - Patent AI Services

正如在项目背景部分所说，RIOS Lab 自 2022 年开始布局 IP 研究以来，积累了大量有关于 IP 工作流程的领域内知识，我们进行了整理并归纳了三大类功能，利用大模型和 AI 算法实现了相关的业务逻辑。

三大功能

- **专利语义分析与推荐**
  - 专利本身的检索和字段的提取
  - 专利本身的语义分析，例如要素提取、权利要求保护、技术特征等
  - 多种模式下的专利推荐，涉及专利保护（IP 保护）
  - 跨专利的语义分析，例如相似性分析、稳定性分析等

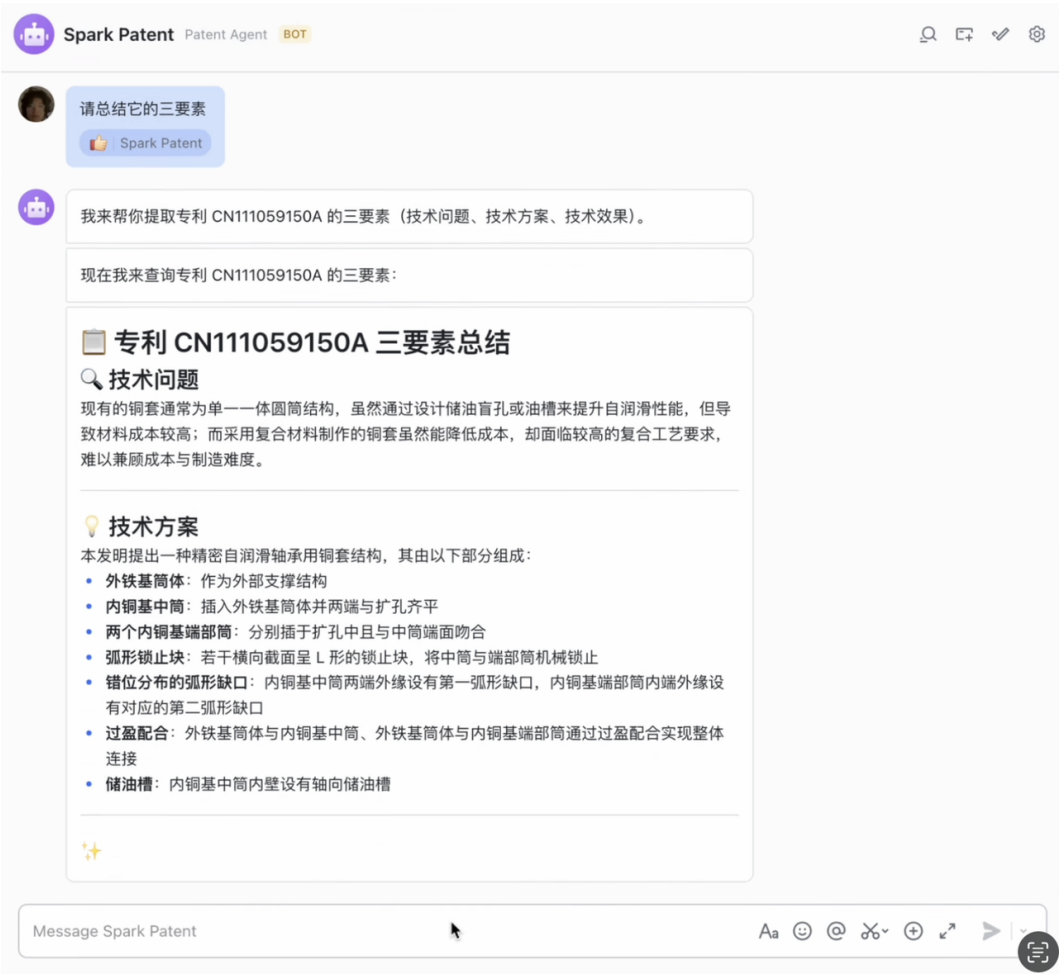

要素提取示例

- **专利智能问数**
  - 用户通过自然语言对专利进行统计分析
  - 核心是 Text2SQL + 查询执行引擎 + 自我勘误机制

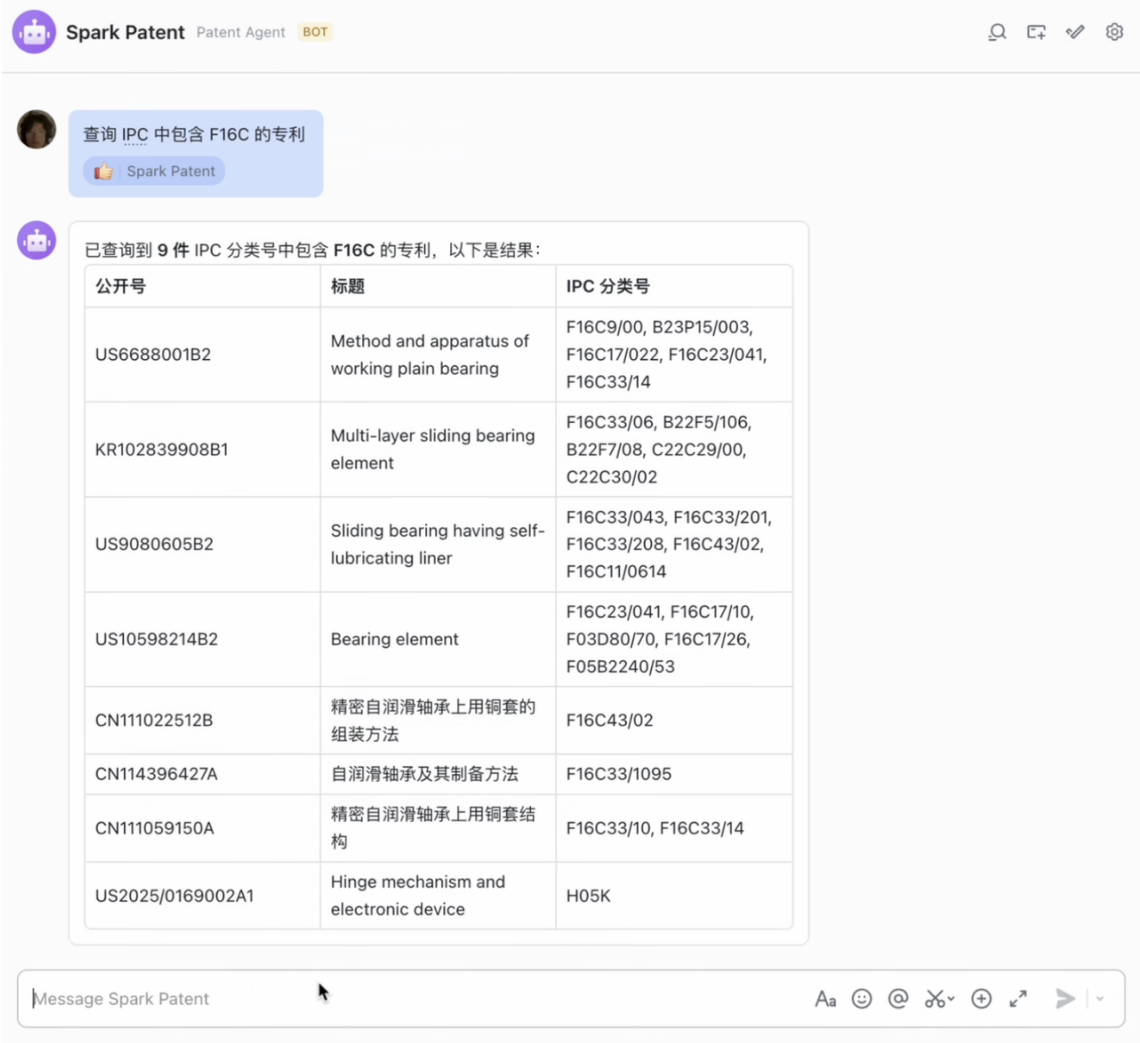

智能问数示例

- **技术主题/问题深度分析**
  - 基于背后的专利库，为用户快速调研、剖析任何技术主题/问题
  - 支持人为反馈（human-in-the-loop）
  - 支持自我反思

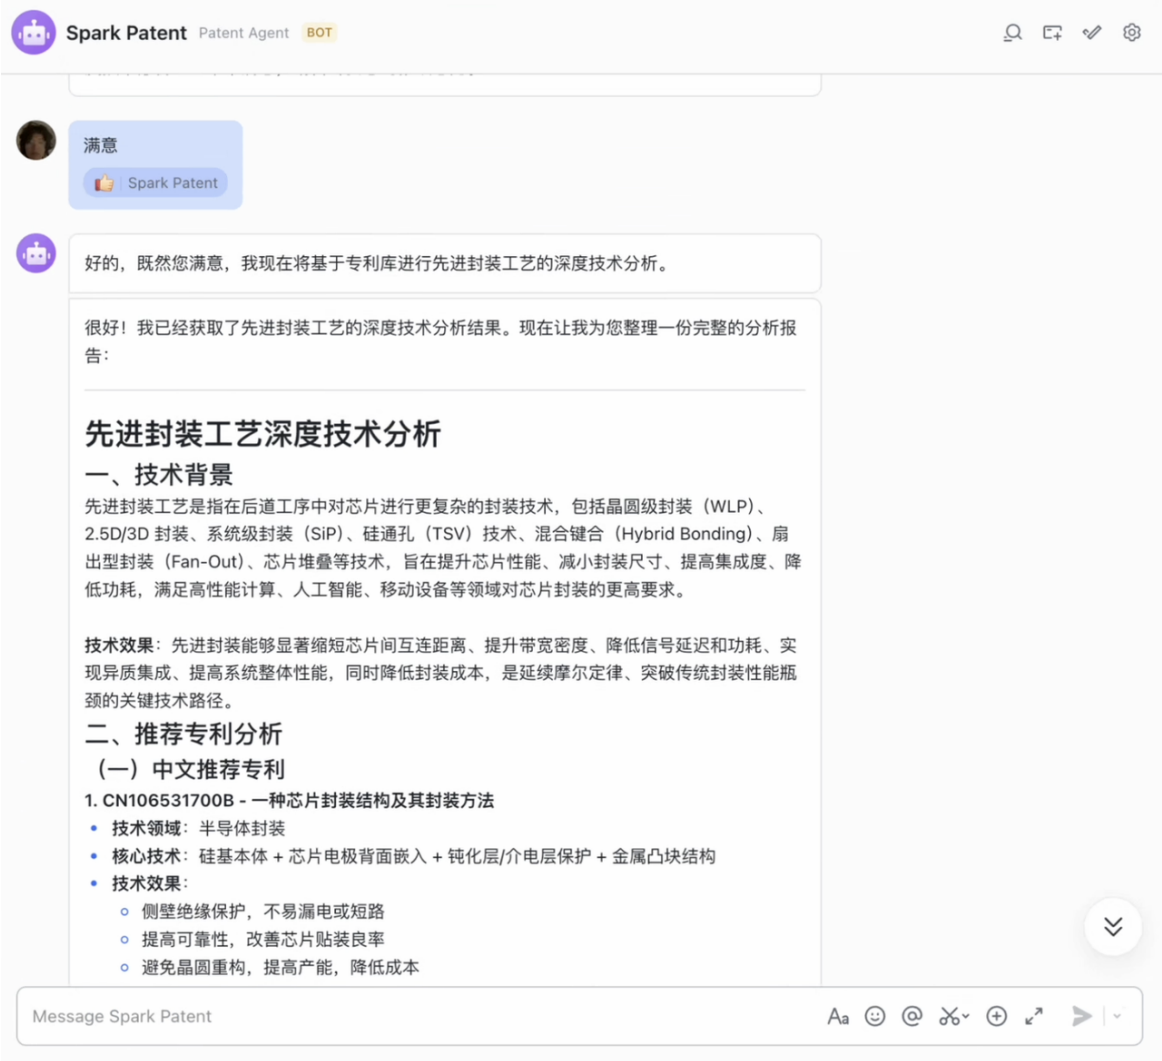

技术深度分析示例

混合检索

以上服务的实现离不开一个核心数据调用机制，混合检索。考虑到实际的业务需要，专利被存储在两个不同类型的数据库中，向量数据库 Milvus 和关系数据库 PostgreSQL，我们所实现的混合检索也涉及两个层面：

- **向量库中的混合检索**
  - 向量的朴素语义拼接
  - 跨文本字段的加权向量检索（默认权重以及基于规则的权重）
  - 跨文本字段的关键词&向量混合检索
- **跨数据库的混合检索**
  - 向量检索结果的再过滤
  - 关系数据库过滤结果的再排序

数据库管理 - Database Management

数据库搭建

本模块负责专利数据的解析接入、分层存储及检索能力支撑。系统采用 **PostgreSQL + Milvus** 的协同架构：其中，PostgreSQL 用于原始专利数据的结构化持久化管理，并作为 Text2SQL 智能问询服务的执行底座；Milvus 用于专利文本的向量化组织与语义检索，为相似专利发现/推荐、语义分析与技术问答等功能提供支撑。

PostgreSQL：结构化持久化存储

PostgreSQL 负责专利数据的结构化持久化管理。其 schema 围绕统一专利对象展开，主要包含：

- 标识字段：publication number、application number
- 时间字段：application date、publication date、grant date
- 主体字段：applicant、inventor、agent
- 分类字段：country code、IPC、status
- 内容字段：title、abstract、claims、description

整体设计上，以 **publication number** 作为关键唯一标识，保证专利记录可唯一定位，并作为与 Milvus 检索结果关联的基础键。

在专利智能问数部分，PostgreSQL 同时作为 Text2SQL 的执行底座。为保证安全性，系统对该服务采用了严格的只读约束：

- Text2SQL 服务使用 **read only** 权限的数据库账号。
- 仅开放 SELECT 权限，不允许执行 INSERT、UPDATE、DELETE、DROP 等写操作。

这种设计保证了自然语言查询能力可用的同时，将数据库执行风险控制在只读范围内，提高了系统的工程安全性。

Milvus：面向语义检索的向量组织

Milvus 主要用于承载专利语义检索所需的向量数据。在数据预处理阶段，针对专利中不同字段的语义功能差异，按 title、abstract、claims、description 四个核心字段对专利内容进行切片、清洗与组织；在向量存储阶段，则以**一篇专利对应一条记录**的方式入库，分别保存四个字段的 embedding 向量，并附带 publication number 作为元数据。

核心处理方式包括：

- 按 title / abstract / claims / description 等字段切片
- 为每个 chunk 保留对应文本内容与 section type
- 以 publication number 作为核心元数据标识和专利级别的统一锚点，用于实现：
  - chunk 结果向原始专利的回溯
  - 检索结果的专利级聚合与去重
  - 向量检索结果与结构化数据的关联

- 已入库专利的更新与清理控制
- 对 chunk 文本生成 embedding 写入向量库

原始专利的解析上传

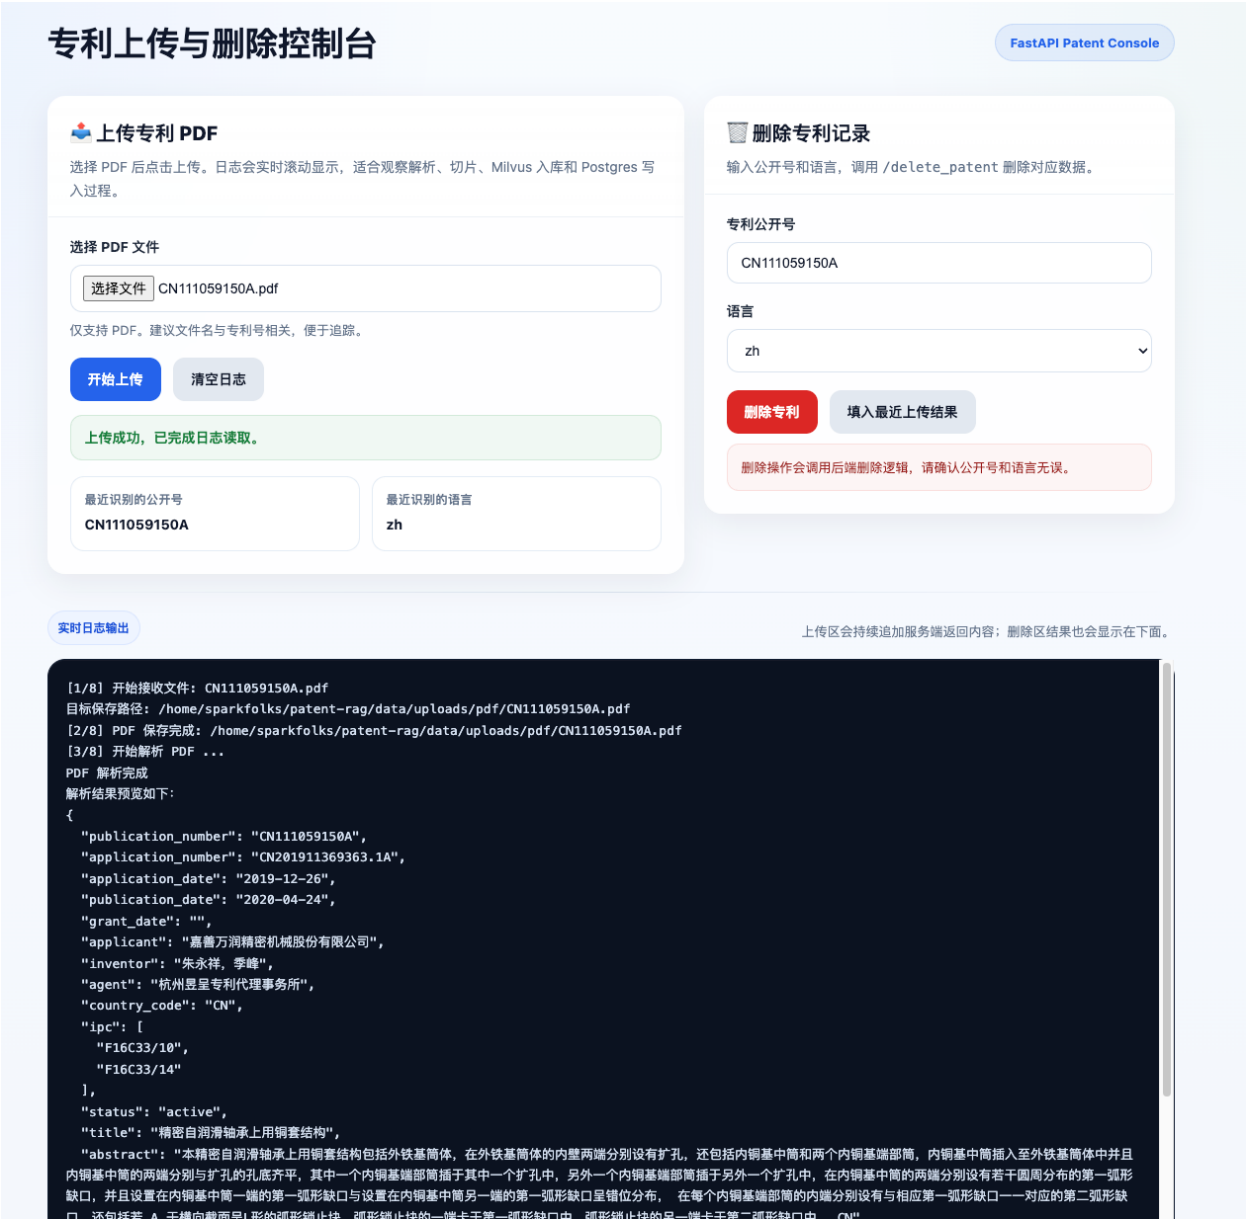

原始专利解析上传示例

原始专利数据以 PDF 形式接入，整体流程如下：

- PDF 上传
- 专利类型与语言判断
- 规则提取与 OCR 补充识别
- 数据清洗与字段标准化
- 切片与向量化入库 Milvus
- 结构化入库 PostgreSQL

在解析阶段，系统首先依据专利号前缀、首页版式与文本特征对文档进行类型判断，将 CN、US、WO 等不同来源专利分配到对应解析路径。对于可直接提取文本的文档，优先采用规则抽取；对于扫描质量较差、文本层缺失或双栏排版干扰明显的文档，则引入 OCR 结果作为补充。之后，对抽取结果进行统一清洗，包括字段归一化、日期标准化、无效噪声剔除、多值字段规整等处理，最终生成统一的专利结构对象。与此同时，系统也提供按公开号删除的维护能力，用于同步移除向量库与关系库中的对应记录，保证数据状态一致。

通用智能体 - Agent

智能体框架选择

在通用智能体的选择上我们对比了当下不同的智能体框架，对于一个 PoC 项目的搭建我们选择了轻量化的 Nanobot (by HKUST)：

- **框架高度轻量化**：仅万行以内的核心代码实现了 OpenClaw 的主要功能，从开发者角度来看是一个可控的“白盒”，更便于后续的定制化开发，高度的开发者友好。
- **高效启动**：秒级的启动时间，便于测试与展示。
- **配置简单**：更轻量化的参数配置和 .md 文件编辑，便于外部技能的快速集成。

专利处理服务集成

- workspace/skills：针对不同的专利处理服务，撰写不同的 SKILL.md；相似、轻量化的技能将会被放置在同一个抽象且宽泛的技能下；复杂、冗长的技能则通过多步骤提示词以及子技能来实现。
- worksapce/{.md files}：在技能层面之上提供更多的额外指示，比如相似技能执行优先级、特殊场景的指导等。
- 安全管理：合理配置工具执行所涉及的 IP 和端口的访问许可。由于项目所有专利处理服务皆部署在本地 DGX Spark 节点，因此需要对本地节点的 IP 和服务端口开通访问许可。

智能体前端接入

Nanobot 支持 10+ 主流通信 App 的接入（微信、企业微信、飞书、QQ、Discord等），在项目中我们使用了飞书用于展示。

总结

- **Spark Patents 是目前专利处理维度最全面的 AI 智能体**，它结合了权威 IP 专家的领域内知识用于支持各种 IP 服务，并且提供用户友好与便捷的交互界面。
- **它的基建具有极高的可靠性**，用于支持高并发 AI 请求以及多元数据存储，同时也拥有灵活的技术扩展性。

- **涉及到的 NVIDIA 技术：**
  - 整个项目完全部署在 NVIDIA DGX SPARK。
  - 使用了 NVIDIA CUDA 加速框架用于支持大模型部署与运行。
  - 使用了 NVIDIA TRITON 后端等相关技术用于支持大模型部署与运行（vLLM 调用）。
  - 使用了 NVIDIA TensorRT-LLM 用于支持大模型部署与运行。